




PHÂN TÍCH DỮ LIỆU VÀ DỰ ĐOÁN NGUY CƠ MẮC BỆNH TIM DỰA TRÊN DỮ LIỆU Y TẾ BẰNG CÁC MÔ HÌNH MACHINE LEARNING

Tìm hiểu trái tim - Bắt đầu từ dữ liệu

GVHD: Phan Thị Thế

THÀNH VIÊN THAM GIA BÁO CÁO



Nguyễn Đình Tấn Lộc
TÌM HIỂU DỮ LIỆU, MERGE CODE



Nguyễn Vũ Minh
TRỰC QUAN DỮ LIỆU



Đình Hoàng Phương
XỬ LÝ DỮ LIỆU



Mai Quốc Thái
HUẤN LUYỆN MÔ HÌNH

BỐ CỤC BÀI THUYẾT TRÌNH

01

GIỚI THIỆU TỔNG QUAN
TÓM TẮT, GIỚI THIỆU

02

MÔ TẢ DỮ LIỆU
LÝ DO CHỌN DỮ LIỆU,
NGUỒN LẤY DỮ LIỆU

03

XỬ LÝ DỮ LIỆU
DỮ LIỆU TRỐNG,
CHUYỂN ĐỔI CÁC FILED

04

TRỰC QUAN DỮ LIỆU
MÔ TẢ BẰNG HÌNH ẢNH

05

MACHINE LEARNING
ÁP DỤNG CÁC MÔ HÌNH
VÀO VIỆC DỰ ĐOÁN

06

KẾT LUẬN
ĐÁNH GIÁ, TÓM TẮT LẠI

01 GIỚI THIỆU TỔNG QUAN

BỐI CẢNH & ĐỘNG LỰC

- Là nguyên nhân gây tử vong hàng đầu toàn cầu.
- Cần phát hiện sớm & điều trị kịp thời.
- ML có tiềm năng hỗ trợ chẩn đoán sớm.

BỆNH TIM MẠCH LÀ NGUYÊN NHÂN GÂY TỬ VONG HÀNG ĐẦU TRÊN TOÀN CẦU



Bệnh tim mạch là tình trạng bệnh lý liên quan đến cấu trúc, hoạt động của trái tim hay của các mạch máu, gây suy yếu khả năng làm việc của tim. Các bệnh tim mạch thường gặp là: bệnh mạch vành, bệnh động mạch ngoại biên, thiếu máu cơ tim, viêm cơ tim, suy tim, rối loạn nhịp tim...

18,6
TRIỆU

người chết
mỗi năm do
bệnh tim
mạch




chiếm
33%
tổng số người
chết toàn cầu

>75%

người chết do bệnh tim mạch
xảy ra ở các quốc gia có thu
nhập thấp đến trung bình

SỐ NGƯỜI CHẾT DO BỆNH TIM MẠCH CAO NHẤT



CÁC YẾU TỐ ẢNH HƯỞNG ĐẾN TIM MẠCH

- Huyết áp cao
- Cholesterol cao
- Thừa cân, béo phì
- Bệnh thận
- Tiểu đường
- Ít vận động
- Chế độ ăn không lành mạnh
- Thuốc lá
- Uống nhiều bia, rượu
- Ô nhiễm không khí

Nguồn: Tổ chức Y tế Thế giới (WHO),
Viện Đánh giá và Đo lường Sức khỏe (IHME), Liên đoàn
Tim mạch Thế giới (WHF)

01 GIỚI THIỆU TỔNG QUAN

MỤC TIÊU & PHẠM VI

MỤC TIÊU	PHẠM VI
Ứng dụng mô hình để dự đoán.	Dữ liệu: Kaggle, UCI.
So sánh để tìm ra mô hình tốt nhất.	Mô hình: Hồi quy Logistic (Logistic Regression), Rừng Ngẫu Nhiên (Random Forest), Tăng Cường Độ Dốc (Gradient Boosting).
Định hướng áp dụng AI trong y tế.	Môi trường: Ngôn ngữ R.

02

MÔ TẢ DỮ LIỆU

NGUỒN GỐC

TÊN FILE GỐC	BỆNH VIỆN	QUỐC GIA
cleveland.data	Cleveland Clinic Foundation	Hoa Kỳ 
hungarian.data	Hungarian Institute of Cardiology	Hungary 
switzerland.data	University Hospital Zurich	Thụy Sĩ 
long-beach-va.data	VA Medical Center, Long Beach	Hoa Kỳ 

02 MÔ TẢ DỮ LIỆU

TẠI SAO LẠI CHỌN?

- Tính đa dạng về nguồn gốc bệnh nhân.
- Mức độ tin cậy cao.
- Là dữ liệu có sẵn và được cộng đồng khoa học xác minh.

WHY CHOOSE US?



age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target	
52	1	0	125	212	0	1	168	0	1	2	2	3	0	
53	1	0	140	203	1	0	155	1	3.1	0	0	3	0	
70	1	0	145	174	0	1	125	1	2.6	0	0	3	0	
61	1	0	148	203	0	1	161	0	0	2	1	3	0	
62	0	0	138	294	1	1	106	0	1.9	1	3	2	0	
58	0	0	100	248	0	0	122	0	1	1	0	2	1	
58	1	0	114	318	0	2	140	0	4.4	0	3	1	0	
55	1	0	160	289	0	0	145	1	0.8	1	1	3	0	
46	1	0	120	249	0	0	144	0	0.8	2	0	3	0	
54	1	0	122	286	0	0	116	1	3.2	1	2	2	0	
71	0	0	112	149	0	1	125	0	1.6	1	0	2	1	
43	0	0	132	341	1	0	136	1	3	1	0	3	0	
34	0	1	118	210	0	1	192	0	0.7	2	0	2	1	
51	1	0	140	298	0	1	122	1	4.2	1	3	3	0	

HEART.CSV

1025 X 14

02

MÔ TẢ DỮ LIỆU

CẤU TRÚC

```
# Hiển thị dữ liệu đã được đọc
```

```
dim(data)
```

```
data_file1
```

```
data_file2
```

```
data_file3
```

```
data_file4
```

```
data_file5
```

```
...
```

R Console

tbl_df
6 x 14

data.frame
303 x 1

data.frame
388 x 1

data.frame
200 x 14

data.frame
123 x 1

Rows: 1025 Columns: 14 — Column specification

Delimiter: ","

dbl (14): age, sex, cp, trestbps, chol, fbs, restecg, thalach, exang, oldpeak, slope, ca, thal, target

i Use 'spec()' to retrieve the full column specification for this data.

i Specify the column types or set 'show_col_types = FALSE' to quiet this message. [1] 1025

14

02

MÔ TẢ DỮ LIỆU

age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target
-----	-----	----	----------	------	-----	---------	---------	-------	---------	-------	----	------	--------

**AGE**

TUỔI CỦA BỆNH NHÂN (ĐƠN VỊ: NĂM)

**CP**

0 = ĐAU THẮT NGỰC ĐIỂN HÌNH,
1 = ĐAU THẮT NGỰC KHÔNG ĐIỂN HÌNH,
2 = KHÔNG ĐAU THẮT NGỰC,
3 = KHÔNG CÓ TRIỆU CHỨNG

CÁC THUỘC TÍNH

**SEX**

GIỚI TÍNH CỦA BỆNH NHÂN, NỮ = 0, NAM = 1

**TRESTBPS**

HUYẾT ÁP KHI NGHỈ NGƠI (MM HG).

02

MÔ TẢ DỮ LIỆU

CÁC THUỘC TÍNH

age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target
-----	-----	----	----------	------	-----	---------	---------	-------	---------	-------	----	------	--------

**CHOL**

MỨC CHOLESTEROL
TRONG MÁU (MG/DL).

**FBS**

LƯỢNG ĐƯỜNG HUYẾT LÚC ĐÓI (>120
MG/DL: 1 = CÓ, 0 = KHÔNG).

**RESTECG**

KẾT QUẢ ĐIỆN TÂM ĐỒ KHI NGHỈ (0 =
BÌNH THƯỜNG, 1 = CÓ BẤT THƯỜNG
SÓNG ST-T, 2 = PHÌ ĐẠI THẤT TRÁI).

**THALACH**

NHỊP TIM TỐI ĐA ĐẠT ĐƯỢC
TRONG BÀI KIỂM TRA GẮNG
SỨC.

02

MÔ TẢ DỮ LIỆU

CÁC THUỘC TÍNH

age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target
-----	-----	----	----------	------	-----	---------	---------	-------	---------	-------	----	------	--------



EXANG

ĐAU THẮT NGỰC DO TẬP THỂ DỤC (1 = CÓ, 0 = KHÔNG).



OLDPEAK

ST DEPRESSION (SỰ SUY GIẢM ĐOẠN ST TRÊN ĐIỆN TÂM ĐỒ SAU KHI TẬP THỂ DỤC, LIÊN QUAN ĐẾN TÌNH TRẠNG THIẾU MÁU CỤC BỘ).



SLOPE

ĐỘ DỐC CỦA ĐOẠN ST TRONG BÀI KIỂM TRA GẮNG SỨC (1 = DỐC LÊN, 2 = BẰNG PHẪNG, 3 =



CA

SỐ LƯỢNG MẠCH MÁU CHÍNH BỊ HẸP (GIÁ TRỊ TỪ 0 ĐẾN 3).

02

MÔ TẢ DỮ LIỆU

CÁC THUỘC TÍNH

age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target
-----	-----	----	----------	------	-----	---------	---------	-------	---------	-------	----	------	--------

THAL



KẾT QUẢ KIỂM TRA THALLIUM (3 = BÌNH THƯỜNG, 6 = KHIẾM KHUYẾT CỐ ĐỊNH, 7 = KHIẾM KHUYẾT CÓ THỂ ĐẢO NGƯỢC).


NUM(TARGET)



CHẨN ĐOÁN BỆNH TIM (0 = KHÔNG MẮC BỆNH TIM, 1 = CÓ BỆNH TIM).

03

XỬ LÝ DỮ LIỆU



CHUẨN HÓA DỮ LIỆU

THỐNG NHẤT CÁC CỘT



MISSING VALUES


DÙNG CÁC HÀM THỐNG KÊ, CHỈ SỐ MÔ TẢ ĐỂ TÌM RA TÍNH CHẤT GIÁ TRỊ



XỬ LÝ OUTLIER

PHÁT HIỆN BẰNG Z - SCORE, XỬ LÝ GIÁ TRỊ CẶN BIÊN





CHUẨN HÓA DỮ LIỆU


THỐNG NHẤT CÁC CỘT

```
x hungarian2 DATA File
x long-beach-va DATA File
x switzerland DATA File
```

Description: df [6 x 14]

	V1 <int>	V2 <int>	V3 <int>	V4 <chr>	V5 <chr>	V6 <chr>	V7 <int>	V8 <chr>	V9 <chr>
1	63	1	4	140	260	0	1	112	1
2	44	1	4	130	209	0	1	127	0
3	60	1	4	132	218	0	1	140	1
4	55	1	4	142	228	0	1	149	1
5	66	1	3	110	213	1	2	99	1
6	66	1	3	120	0	0	1	120	0

6 rows | 1-10 of 14 columns



CHUẨN HÓA DỮ LIỆU


x hungarian DATA File

```
1 28,1,2,130,132,0,2,185,0,0,?,?,?,0
2 29,1,2,120,243,0,0,160,0,0,?,?,?,0
- - - - -
```


x cleveland DATA File

```
1 63.0,1.0,1.0,145.0,233.0,1.0,2.0,150.0,0.0,2.3,3.0,0.0,6.0,0
2 67.0,1.0,4.0,160.0,286.0,0.0,2.0,108.0,1.0,1.5,2.0,3.0,3.0,2
```

Hàm separate



Các cột được
tách ra tương ứng



CHUẨN HÓA DỮ LIỆU

Áp dụng cho các dataframe, đưa về kiểu numeric và điền các giá trị trống bằng NA:

`mute_all(as.numeric)`

Gán tên cột cho các dataframe với vector colnames các thuộc tính sau:

`("age", "sex", "cp", "trestbps", "chol",
"fbs", "restecg", "thalach", "exang",
"oldpeak", "slope", "ca", "thal", "target")`

Gộp các dataframe lại thành một file csv duy nhất


`heart_all_combined.csv`

THỐNG KÊ MÔ TẢ



MIN (GIÁ TRỊ NHỎ NHẤT) VÀ MAX (GIÁ TRỊ LỚN NHẤT):

- MIN LÀ GIÁ TRỊ NHỎ NHẤT TRONG TẬP DỮ LIỆU.
- MAX LÀ GIÁ TRỊ LỚN NHẤT TRONG TẬP DỮ LIỆU.
- CẢ HAI CHỈ SỐ NÀY GIÚP XÁC ĐỊNH PHẠM VI (RANGE) CỦA DỮ LIỆU, TỨC LÀ KHOẢNG CÁCH GIỮA GIÁ TRỊ NHỎ NHẤT VÀ LỚN NHẤT.



MEAN (TRUNG BÌNH CỘNG):

- LÀ GIÁ TRỊ TRUNG BÌNH CỦA TẤT CẢ CÁC ĐIỂM DỮ LIỆU TRONG TẬP. ĐÂY LÀ CHỈ SỐ PHỔ BIẾN NHẤT ĐỂ MÔ TẢ TRUNG TÂM CỦA DỮ LIỆU.
- CÔNG THỨC TÍNH:


$$\text{Mean} = \frac{\sum X_i}{n}$$

THỐNG KÊ MÔ TẢ



MEDIAN (TRUNG VỊ):

- LÀ GIÁ TRỊ GIỮA TRONG MỘT TẬP DỮ LIỆU ĐÃ ĐƯỢC SẮP XẾP THEO THỨ TỰ TỪ NHỎ ĐẾN LỚN. NẾU CÓ SỐ LƯỢNG DỮ LIỆU CHẴN, TRUNG VỊ LÀ TRUNG BÌNH CỦA HAI GIÁ TRỊ GIỮA.
- TRUNG VỊ GIÚP LOẠI BỎ ẢNH HƯỞNG CỦA CÁC GIÁ TRỊ NGOẠI LAI.



SD (ĐỘ LỆCH CHUẨN):

- ĐO ĐỘ PHÂN TÁN CỦA DỮ LIỆU, TỨC LÀ MỨC ĐỘ MÀ CÁC GIÁ TRỊ DỮ LIỆU PHÂN TÁN QUANH GIÁ TRỊ TRUNG BÌNH.
- CÔNG THỨC TÍNH:

$$SD = \sqrt{\frac{\sum (X_i - \mu)^2}{n}}$$

THỐNG KÊ MÔ TẢ



CV (HỆ SỐ BIẾN THIÊN - COEFFICIENT OF VARIATION):

- LÀ TỶ LỆ GIỮA ĐỘ LỆCH CHUẨN VÀ GIÁ TRỊ TRUNG BÌNH, GIÚP ĐO LƯỜNG MỨC ĐỘ BIẾN ĐỘNG TƯƠNG ĐỐI CỦA DỮ LIỆU.
- CÔNG THỨC TÍNH:

$$CV = \frac{SD}{Mean} \times 100\%$$



MISSING VALUES

Sử dụng `colSums(is.na(data))` để thống kê số lượng giá trị NA

Cột	Số NA	%NA	Ghi chú thêm
<u>age</u>	94	7.2%	<u>Tương đối ít</u>
<u>sex</u>	94	7.2%	<u>Ít</u>
<u>cp</u>	94	7.2%	<u>Ít</u>
<u>trestbps</u>	154	11.8%	<u>Có thể giữ lại</u>
<u>chol</u>	147	11.2%	<u>Có thể xử lý được</u>
<u>fbs</u>	192	14.7%	<u>Hơi cao, nhưng vẫn xử lý được</u>
<u>restecg</u>	97	7.4%	<u>Ít</u>
<u>thalach</u>	150	11.5%	<u>Trung bình</u>
<u>exang</u>	150	11.5%	<u>Trung bình</u>
<u>oldpeak</u>	156	11.9%	<u>Trung bình</u>
<u>slope</u>	593	45.3%	<u>Quá cao</u>
<u>ca</u>	995	76.1%	<u>Rất cao</u>
<u>thal</u>	846	64.7%	<u>Rất cao</u>
<u>target</u>	94	7.2%	<u>Quan trọng, cần giữ</u>

MISSING VALUES

CV > 0.5 : (TỨC LÀ DỮ LIỆU BIẾN ĐỘNG MẠNH), CÁC GIÁ TRỊ THIẾU SẼ ĐƯỢC ĐIỀN NGẪU NHIÊN (RANDOM IMPUTATION) TRONG KHOẢNG:

$$[\max(\min, \text{mean} - \text{sd}), \min(\max, \text{mean} + \text{sd})]$$

CV <= 0.5 : GIÁ TRỊ THIẾU SẼ ĐƯỢC ĐIỀN BẰNG MEDIAN, GIÚP GIẢM ẢNH HƯỞNG CỦA CÁC GIÁ TRỊ NGOẠI LAI.

ĐỐI VỚI BIẾN PHÂN LOẠI (CATEGORICAL/BINARY):

- GIÁ TRỊ THIẾU SẼ ĐƯỢC ĐIỀN BẰNG MODE (GIÁ TRỊ XUẤT HIỆN NHIỀU NHẤT), VÌ MODE ĐẠI DIỆN CHO XU HƯỚNG PHỔ BIẾN NHẤT CỦA BIẾN PHÂN LOẠI.

	age	sex	cp	trestbps	chol	fbs			
	0	0	0	0	0	0			
restecg	thalach	exang	oldpeak	slope	ca	thal	target		
0	0	0	0	0	0	0	0		0

age<dbl>	sex<dbl>	cp<dbl>	trestbps<dbl>	chol<dbl>	fbs<dbl>	restecg<dbl>	thalach<dbl>	exang<dbl>	oldpeak<dbl>
63	1.0000000	1	145	233.0	1.0000000000	2.0000000000	150	0.000000000	2.300000000
67	1.0000000	4	160	286.0	0.0000000000	2.0000000000	108	1.000000000	1.500000000
67	1.0000000	4	120	229.0	0.0000000000	2.0000000000	129	1.000000000	2.600000000
37	1.0000000	3	130	250.0	0.0000000000	0.0000000000	187	0.000000000	3.500000000
41	0.0000000	2	130	204.0	0.0000000000	2.0000000000	172	0.000000000	1.400000000
56	1.0000000	2	120	236.0	0.0000000000	0.0000000000	178	0.000000000	0.800000000
62	0.0000000	4	140	268.0	0.0000000000	2.0000000000	160	0.000000000	3.600000000
57	0.0000000	4	120	354.0	0.0000000000	0.0000000000	163	1.000000000	0.600000000
63	1.0000000	4	130	254.0	0.0000000000	2.0000000000	147	0.000000000	1.400000000
53	1.0000000	4	140	203.0	1.0000000000	2.0000000000	155	1.000000000	3.100000000

1-10 of 1,308 rows | 1-10 of 28 columns

Previous123456...100Next

OUTLIER



OUTLIER LÀ GÌ ?

- Sai sót khi nhập liệu
- Dữ liệu hiếm gặp nhưng hợp lệ
- Biến cố đặc biệt trong thực tế

OUTLIER LÀ GÌ ?

Z-score đo độ lệch chuẩn của một giá trị so với trung bình:

CÁCH PHÁT HIỆN OUTLIER

- Giá trị cần kiểm tra
- Trung bình của biến
- Độ lệch chuẩn
- Nếu $|Z| > 3$ thì giá trị đó có thể là outlier

XỬ LÝ OUTLIER

- NẾU GIÁ TRỊ $>$ UPPER BOUND $\rightarrow$ GÁN = UPPER BOUND
- NẾU GIÁ TRỊ $<$ LOWER BOUND $\rightarrow$ GÁN = LOWER BOUND

$$Z = \frac{X - \mu}{\sigma}$$

$$\text{Lower bound} = \mu - 3\sigma$$

$$\text{Upper bound} = \mu + 3\sigma$$

04 TRỰC QUAN HÓA DỮ LIỆU

Mục đích: Hiểu rõ cấu trúc dữ liệu, khám phá mối quan hệ giữa các biến

Các loại biểu đồ sử dụng:

Histogram

Scatter plot

Boxplot

Cor_matrix

Geom_bar


MỘT SỐ BIỂU ĐỒ CÓ THỂ VẼ



SO SÁNH NHỊP TIM TỐI ĐA THEO BỆNH TIM (BOXPLOT)

MỤC TIÊU:

- ĐỂ SO SÁNH NHỊP TIM TỐI ĐA GIỮA NGƯỜI CÓ BỆNH TIM VÀ KHÔNG CÓ BỆNH TIM.
- SỰ KHÁC BIỆT TRONG NHỊP TIM TỐI ĐA CÓ THỂ CHO THẤY ẢNH HƯỞNG CỦA BỆNH TIM ĐẾN HOẠT ĐỘNG TIM MẠCH, GIÚP ĐƯA RA NHỮNG PHƯƠNG ÁN ĐIỀU TRỊ VÀ THEO DÕI PHÙ HỢP.



SO SÁNH ĐỘ GIẢM ST (OLDPEAK) THEO TÌNH TRẠNG BỆNH TIM (BOXPLOT)

MỤC TIÊU:

- BIỂU ĐỒ NÀY SO SÁNH MỨC ĐỘ GIẢM ST (OLDPEAK) GIỮA HAI NHÓM: NHỮNG NGƯỜI KHÔNG CÓ BỆNH TIM VÀ NHỮNG NGƯỜI CÓ BỆNH TIM.
- MỤC TIÊU LÀ HIỂU RÕ HƠN VỀ MỐI LIÊN HỆ GIỮA ĐỘ GIẢM ST VÀ TÌNH TRẠNG BỆNH TIM.

MỘT SỐ BIỂU ĐỒ CÓ THỂ VỀ

SỐ MẠCH MÁU BỊ HẸP THEO TÌNH TRẠNG BỆNH TIM



MỤC TIÊU:

- BIỂU ĐỒ NÀY MINH HỌA MỐI QUAN HỆ GIỮA SỐ LƯỢNG MẠCH MÁU BỊ HẸP VÀ TÌNH TRẠNG BỆNH TIM.
- NHẪM GIÚP NHẬN BIẾT NGUY CƠ MẮC BỆNH TIM DỰA TRÊN SỐ LƯỢNG MẠCH MÁU BỊ HẸP.
- SỐ MẠCH MÁU BỊ HẸP CÀNG NHIỀU, TỶ LỆ MẮC BỆNH TIM CÀNG CAO.


Ma trận tương quan giữa các biến:




MỤC TIÊU:

- BIỂU ĐỒ NHIỆT NÀY MINH HỌA MỐI TƯƠNG QUAN GIỮA CÁC BIẾN TRONG TẬP DỮ LIỆU
- VIỆC PHÂN TÍCH MA TRẬN TƯƠNG QUAN GIÚP XÁC ĐỊNH CÁC ĐẶC TRƯNG QUAN TRỌNG, TỐI ƯU HÓA HIỆU QUẢ CỦA MÔ HÌNH DỰ ĐOÁN VÀ HỖ TRỢ QUYẾT ĐỊNH LÂM SÀNG.


Phân bố độ tuổi (Age) theo giới tính (Sex)




Biểu đồ thể hiện mối quan hệ giữa Cholesterol và Huyết áp nghỉ theo tình trạng bệnh tim




Boxplot của độ giãn ST (oldpeak) theo tình trạng đau thắt ngực do gắng sức (exang)




Số mạch máu bị hẹp (ca) theo tình trạng bệnh tim (target)




Phân bố số lượng bệnh nhân theo loại đau ngực (cp) và tình trạng bệnh tim (target)




Mối quan hệ giữa kết quả kiểm tra Thallium (thal) và tình trạng bệnh tim (target)



Mối quan hệ giữa nhịp tim tối đa (thalach) và độ giãn ST (oldpeak) theo tình trạng bệnh tim (target)



Ma trận tương quan giữa các biến trong tập dữ liệu



05 MACHINE LEARNING

CÁC MÔ HÌNH HUẤN LUYỆN DỰ ĐOÁN

HỒI QUY LOGISTIC (LOGISTIC REGRESSION)

RỪNG NGẪU NHIÊN (RANDOM FOREST)

TĂNG CƯỜNG ĐỘ DỐC (GRADIENT BOOSTING)

MÔ HÌNH HỒI QUY LOGISTIC



Hồi quy logistic là một kỹ thuật phân loại cho bài toán nhị phân, sử dụng hàm logistic để dự đoán xác suất của một sự kiện xảy ra

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n)}}$$

Tìm các hệ số $\beta_0, \beta_1, \dots, \beta_n$ sao cho hàm likelihood (hàm khả năng) đạt giá trị lớn nhất, tức là tìm tập hợp hệ số khiến mô hình khớp với dữ liệu quan sát tốt nhất.

MÔ HÌNH HỒI QUY LOGISTIC



Dự đoán nguy cơ mắc bệnh: Hồi quy logistic được sử dụng để dự đoán khả năng mắc các bệnh như tiểu đường, bệnh tim mạch, ung thư, v.v.

Phân tích sống sót: Trong nghiên cứu lâm sàng, hồi quy logistic giúp xác định yếu tố nguy cơ ảnh hưởng đến tỷ lệ sống sót của bệnh nhân.

Chấm điểm tín dụng (credit scoring): Dự đoán khả năng một khách hàng không trả được nợ.

Phát hiện gian lận tài chính: Phân loại các giao dịch bất thường.

MÔ HÌNH HỒI QUY LOGISTIC



Trong ngôn ngữ R, hồi quy logistic được thực hiện dễ dàng với hàm `glm()` – viết tắt của `generalized linear model`

```
model <- glm(heart_disease ~ age + sex + cholesterol + cp, data = dataset,  
family = binomial)
```

$$P(\text{bệnh tim}) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 \cdot \text{age} + \beta_2 \cdot \text{sex} + \beta_3 \cdot \text{cholesterol} + \beta_4 \cdot \text{cp})}}$$

Các tham số trong mô hình dự đoán

age	sex	cp	trestbps	chol	fbs	restecg
-0.008691	-1.819684	0.786254	-0.017666	-0.005499	0.060584	0.410917
thalach	exang	oldpeak	slope	ca		
0.023392	-0.982808	-0.512094	0.558013	-0.693303		

RANDOM FOREST



CÂY QUYẾT ĐỊNH LÀ MỘT MÔ HÌNH DỰ ĐOÁN CÓ CẤU TRÚC GIỐNG NHƯ CÂY (GỐC, NHÁNH, LÁ), ĐƯỢC SỬ DỤNG ĐỂ:

PHÂN LOẠI (CLASSIFICATION): DỰ ĐOÁN MỘT NHÃN (LABEL)

HỒI QUY (REGRESSION): DỰ ĐOÁN MỘT GIÁ TRỊ SỐ

CÂY HOẠT ĐỘNG BẰNG CÁCH CHIA NHỎ DỮ LIỆU THÀNH CÁC NHÓM CON, DỰA TRÊN GIÁ TRỊ CỦA CÁC ĐẶC TRƯNG (FEATURES), ĐẾN KHI ĐẠT ĐƯỢC QUYẾT ĐỊNH (DỰ ĐOÁN).

Tuổi	Huyết áp	Cholesterol	Bị bệnh tim
<45	Bình thường	Bình thường	✗ Không
>60	Cao	Cao	✓ Có
50	Cao	Cao	✓ Có
40	Bình thường	Cao	✗ Không
>60	Cao	Bình thường	✓ Có



RANDOM FOREST



KẾT HỢP NHIỀU CÂY QUYẾT ĐỊNH (DECISION TREES) ĐỂ TĂNG ĐỘ CHÍNH XÁC VÀ GIẢM OVERFITTING.

LẤY MẪU NGẪU NHIÊN .

TẠO NHIỀU CÂY QUYẾT ĐỊNH ĐỘC LẬP, SAU ĐÓ LẤY TRUNG BÌNH/KẾT QUẢ ĐA SỐ.

Dự đoán nguy cơ mắc bệnh: Random forest được sử dụng để dự đoán khả năng mắc các bệnh như tiểu đường, bệnh tim mạch, ung thư, v.v.

Phân tích sống sót: Trong nghiên cứu lâm sàng, hồi quy logistic giúp xác định yếu tố nguy cơ ảnh hưởng đến tỷ lệ sống sót của bệnh nhân.

Chấm điểm tín dụng (credit scoring): Dự đoán khả năng một khách hàng không trả được nợ.

Phát hiện gian lận tài chính: Phân loại các giao dịch bất thường.

Tuổi	Huyết áp	Cholesterol	Bệnh tim (0: Không, 1: Có)
45	Cao	Cao	1
50	Bình thường	Cao	1
40	Cao	Bình thường	0
55	Cao	Cao	1
35	Bình thường	Bình thường	0


RANDOM FOREST

Tuổi	Huyết áp	Cholesterol	Bệnh tim
45	Cao	Cao	1
50	Bình thường	Cao	1
55	Cao	Cao	1
40	Cao	Bình thường	0
45	Cao	Cao	1

Tuổi	Huyết áp	Cholesterol	Bệnh tim
45	Cao	Cao	1
50	Bình thường	Cao	1
50	Bình thường	Cao	1
40	Cao	Bình thường	0
55	Cao	Cao	1


Tuổi	Huyết áp	Cholesterol	Bệnh tim
45	Cao	Cao	1
50	Bình thường	Cao	1
35	Bình thường	Bình thường	0
55	Cao	Cao	1
50	Bình thường	Cao	1

RANDOM FOREST



```
library(randomForest)
```

```
model_rf <- randomForest(heart_disease ~ ., data = train_data, ntree = 100)
```



Ưu điểm: Xử lý tốt dữ liệu phi tuyến tính, giảm overfitting, xác định tầm quan trọng của đặc trưng.

Nhược điểm: Tốn tài nguyên tính toán, khó diễn giải hơn hồi quy logistic.

GRADIENT BOOSTING



GRADIENT BOOSTING LÀ MỘT THUẬT TOÁN ENSEMBLE LEARNING, KẾT HỢP NHIỀU MÔ HÌNH YẾU (THƯỜNG LÀ CÂY QUYẾT ĐỊNH NÔNG – DECISION STUMPS) THEO CÁCH TUẦN TỰ, ĐỂ TẠO THÀNH MỘT MÔ HÌNH MẠNH.

Dự đoán nguy cơ mắc bệnh: được sử dụng để dự đoán khả năng mắc các bệnh như tiểu đường, bệnh tim mạch, ung thư, v.v.

Phân tích sống sót: Trong nghiên cứu lâm sàng, giúp xác định yếu tố nguy cơ ảnh hưởng đến tỷ lệ sống sót của bệnh nhân.

Chấm điểm tín dụng (credit scoring): Dự đoán khả năng một khách hàng không trả được nợ.

Phát hiện gian lận tài chính: Phân loại các giao dịch bất thường.

Bệnh nhân	Tuổi	Cholesterol	Nhịp tim	Nhãn thực tế (Y)
A	60	250	140	1
B	45	200	130	0
C	70	280	150	1
D	50	210	120	0
E	65	260	160	1

$$F_0(x) = \log \text{odds}(p) = \log \left(\frac{3}{2} \right) \approx 0.405$$

=> Chuyển về xác suất bằng sigmoid:

$$P_0(x) = \frac{1}{1 + e^{-0.405}} \approx 0.6$$

Bệnh nhân	Y	$P_0(x)$	Residual ($r = y - p$)
A	1	0.6	+0.4
B	0	0.6	-0.6
C	1	0.6	+0.4
D	0	0.6	-0.6
E	1	0.6	+0.4

Giả sử Tree 1 học được quy tắc:

Nếu tuổi > 55 $\rightarrow$ +0.4

Nếu tuổi $\leq$ 55 $\rightarrow$ -0.6

$$F_1(x) = F_0(x) + 0.1 * Tree1(x)$$

Bệnh nhân	Tree1(x)	F ₁ (x)	P ₁ (x) = sigmoid(F ₁ (x))
A	+0.4	0.405 + 0.04 = 0.445	0.61
B	-0.6	0.405 - 0.06 = 0.345	0.59
C	+0.4	0.445	0.61
D	-0.6	0.345	0.59
E	+0.4	0.445	0.61

Tiếp tục tính residual mới dựa trên P₁(x), huấn luyện Cây 2, cập nhật thêm... Quá trình lặp lại tạo nên mô hình mạnh hơn sau mỗi vòng.

GRADIENT BOOSTING



```
library(GBM)
```

```
MODEL_GBM <- GBM(HEART_DISEASE ~ .,  
  DATA = TRAIN_DATA,  
  DISTRIBUTION = "BERNOULLI",  
  N.TREES = 100,  
  INTERACTION.DEPTH = N,  
  SHRINKAGE = 0.1  
)
```

Ưu điểm: Độ chính xác cao, linh hoạt với dữ liệu phức tạp.

Nhược điểm: Dễ overfitting nếu không điều chỉnh tham số, thời gian huấn luyện lâu.

06

KẾT LUẬN

**Ưu điểm**

- Ứng dụng được nhiều mô hình học máy phổ biến và hiệu quả.
- Dữ liệu được tiền xử lý kỹ lưỡng, đảm bảo chất lượng đầu vào.
- Trực quan hóa đa dạng, giúp hiểu rõ mối quan hệ giữa các biến.
- Mô hình dự đoán có độ chính xác cao, đặc biệt là Gradient Boosting.
- Có hướng phát triển giao diện cho người dùng sử dụng thực tế.



Hạn chế

- Bước xử lý dữ liệu (giá trị ngoại lai) chưa được tối ưu.
- Thiếu so sánh thời gian huấn luyện giữa các mô hình.
- Giao diện chưa hoàn thiện, chỉ chạy ở local host.



Cải tiến

- Cải thiện bước xử lý giá trị ngoại lai để tăng độ sạch và chính xác của dữ liệu.
- Mở rộng thử nghiệm thêm mô hình mới để nâng cao hiệu suất dự đoán.

**CẢM ƠN THẦY CÔ VÀ CÁC BẠN
ĐÃ THEO DÕI BÀI BÁO CÁO
LÍ THUYẾT CỦA NHÓM**